Untuk melihat codes, hasil, dan alasan dari langkah-langkah yang digunakan dapat dilihat secara lengkap melalui link colab berikut https://colab.research.google.com/drive/lkUfe36bRoWCmJmVnj8SaR6dp-51EoRxD? usp=sharing

```
INPUT MODEL DAN DATA SET
import pandas as pd
import numpy as np
import statsmodels.formula.api as smf
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import StandardScaler
from statsmodels.stats.outliers influence import variance inflation factor
from sklearn.decomposition import PCA
from statsmodels.stats.stattools import durbin watson
from sklearn.preprocessing import QuantileTransformer
#!qdown 1yiQEpSMzYND8HBO naAqM1e8q0FwPDmB #download data
!qdown 1Q3siqu3VvXSxkI2uxqWjGaeIMM4XWx6z #download dadta
!qdown 1EJzlaxjdvIiAe2nGXJBCly7Be5Y2RlCt #download peta
df = pd.read excel('/content/datasatu.xlsx')
df.columns = df.columns.str.replace(' ', ' ')
df['Provinsi'] = df['Provinsi'].map(lambda x: x.lower())
DATA INFORMATION
df.head()
df.info()
df.describe()
EDA
from mpl toolkits.axes grid1 import make axes locatable
from math import ceil
import geopandas as gpd
peta = gpd.read file('./peta id.geojson')
peta = peta.merge(df, left on='WADMPR',
right on='Provinsi').drop(columns='Provinsi')
feat = df.columns[2:]
y = df.columns[1]
```

```
ncol = 3
fig, ax = plt.subplots(1 + len(feat)//ncol + ceil(len(feat)%ncol/ncol),
ncol, figsize=(20,23), dpi=150)
gs = ax[0,0].get gridspec()
for nowAx in ax[0, :]:
   nowAx.remove()
ax = np.delete(ax, 0, 0)
gs = fig.add subplot(gs[0, :])
for nowAx in np.append(ax.flatten(), gs):
    nowAx.spines['top'].set visible(False)
   nowAx.spines['bottom'].set visible(False)
   nowAx.spines['left'].set visible(False)
   nowAx.spines['right'].set visible(False)
   nowAx.get yaxis().set visible(False)
    nowAx.get xaxis().set visible(False)
colors = ['PuBu', 'Reds', 'Greens', 'Oranges']
gs.set(title='P1')
divider = make axes locatable(gs)
cax = divider.append axes("right", size="2.4%", pad=0.05)
peta.plot(column='P1',
          cmap=colors[-1],
         legend=True,
         ax=gs,
         cax=cax)
for i, j in enumerate(feat):
    nowAx = ax[i//ncol, i%ncol]
   nowAx.set(title=j)
    divider = make axes locatable(nowAx)
    cax = divider.append_axes("right", size="2.4%", pad=0.05)
    peta.plot(column=j,
              cmap=colors[i%len(colors)],
```

```
legend=True,
             ax=nowAx,
             cax=cax)
sns.pairplot(df, y vars=['P1'])
PREPROCESSING
Missing Values
missing count = df.isnull().sum()
missing percentage = (missing count / len(df)) * 100
missing percentage
Standarisasi
cols to process = ['Tingkat Pengangguran', 'apm sd', 'apm smp',
                   'apm sma', 'Berusaha Sendiri',
                   'Berusaha Dibantu Buruh Tidak Tetap',
                   'Berusaha Dibantu Buruh Tetap', 'Buruh',
                   'Pekerja Bebas', 'Pekerja Tidak Dibayar',
                   'Upah Per Jam']
scaler = StandardScaler()
df[cols to process] = scaler.fit transform(df[cols_to_process])
df.head()
Multikolinearitas
#Kolom provinsi tidak masuk karena kateogri dan P1 adalah variabel
dependen
X = df[[col for col in df.select dtypes(include=['number']).columns
         if col not in ['P1', 'Provinsi' ]]]
# 2. Hitung VIF untuk setiap variabel
vif = pd.DataFrame()
vif["Variable"] = X.columns
vif["VIF"] = [variance inflation factor(X.values, i)
                   for i in range(X.shape[1])]
# 3. Tampilkan hasil VIF
print(vif)
plt.figure(figsize=(10, 8)) # Mengatur ukuran heatmap
sns.heatmap(X.corr(), annot=True, cmap='coolwarm', fmt=".2f") # Membuat
heatmap
plt.title('Heatmap Korelasi Variabel X') # Menambahkan judul
plt.show() # Menampilkan heatmap
df = df.drop(['Pekerja Tidak Dibayar'], axis=1)
```

```
#Kolom kabupaten tidak masuk karena kateogri dan wpoor adalah variabel
dependen
X = df[[col for col in df.select dtypes(include=['number']).columns
         if col not in ['P1', 'Provinsi']]]
# 2. Hitung VIF untuk setiap variabel
vif = pd.DataFrame()
vif["Variable"] = X.columns
vif["VIF"] = [variance inflation factor(X.values, i)
                   for i in range(X.shape[1])]
# 3. Tampilkan hasil VIF
print(vif)
SCATTER PLOT
y = df['P1']
X = df.drop(columns=['P1'])
plt.figure(figsize=(8, 6))
plt.scatter(X.iloc[:, 0], y, color='blue', alpha=0.7)
plt.title("Scatter Plot of X and Y")
plt.xlabel(X.columns[0]) # Set x-axis label to the first column name of X
plt.ylabel("Y")
plt.grid(True, linestyle='--', alpha=0.7)
plt.show()
OLS
Model 1
formula = 'P1 ~ Tingkat Pengangguran + apm sd + apm smp + apm sma +
Berusaha Sendiri + Berusaha Dibantu Buruh Tetap + Buruh + Pekerja Bebas +
Upah Per Jam + Berusaha Dibantu Buruh Tidak Tetap'
# Membuat dan melatih model
model1 = smf.ols(formula=formula, data=df).fit()
# Menampilkan ringkasan model
print(model1.summary())
Transformasi Logaritma
from sklearn.preprocessing import QuantileTransformer
import numpy as np
import pandas as pd
```

```
# Inisialisasi transformer
transformer = QuantileTransformer(output distribution='normal',
random state=0, n quantiles=38)
# Salin dataset
df t = df.copy()
# Penanganan nilai inf, NaN, dan negatif
for column in ['Tingkat Pengangguran', 'apm sd', 'apm smp', 'apm sma',
               'Berusaha Sendiri', 'Berusaha Dibantu Buruh Tetap',
               'Berusaha Dibantu Buruh Tidak Tetap', 'Buruh',
               'Pekerja Bebas', 'Upah Per Jam']:
   df t[column] = df t[column].replace([np.inf, -np.inf], np.nan) #
Ganti inf dengan NaN
   df t[column].fillna(0, inplace=True) # Ganti NaN dengan 0
   df t[column] = np.maximum(df t[column], 0) # Pastikan nilai negatif
menjadi 0
# Transformasi log
df t['ln Pl'] = np.log(df t['Pl'] + 1)
df t['ln Tingkat Pengangguran'] = np.log(df t['Tingkat Pengangguran'] + 1)
df t['ln apm sd'] = np.log(df t['apm sd'] + 1)
df t['ln apm smp'] = np.log(df t['apm smp'] + 1)
df t['ln apm sma'] = np.log(df t['apm sma'] + 1)
df t['ln Berusaha Sendiri'] = np.log(df t['Berusaha Sendiri'] + 1)
df t['ln Berusaha Dibantu Buruh Tetap'] =
np.log(df t['Berusaha Dibantu Buruh Tetap'] + 1)
df t['ln Berusaha Dibantu Buruh Tidak Tetap'] =
np.log(df t['Berusaha Dibantu Buruh Tidak Tetap'] + 1)
df t['ln Buruh'] = np.log(df t['Buruh'] + 1)
df t['ln Pekerja Bebas'] = np.log(df t['Pekerja Bebas'] + 1)
df_t['ln_Upah_Per_Jam'] = np.log(df_t['Upah_Per_Jam'] + 1)
# Kolom log-transform yang akan ditransformasi lebih lanjut
log columns = [
    'ln Tingkat Pengangguran', 'ln apm sd', 'ln apm smp', 'ln apm sma',
    'ln Berusaha Sendiri', 'ln Berusaha Dibantu Buruh Tetap', 'ln Buruh',
    'ln_Pekerja_Bebas', 'ln_Upah_Per_Jam',
'ln Berusaha Dibantu Buruh Tidak Tetap'
```

```
# Terapkan QuantileTransformer
df t[log columns] = transformer.fit transform(df t[log columns])
Model 2
# Formula dengan nama kolom yang tepat menggunakan tanda kutip
formula = 'P1 ~ ln Tingkat Pengangguran + ln apm sd + ln apm smp +
ln apm sma + ln Berusaha Sendiri + ln Berusaha Dibantu Buruh Tetap +
ln Buruh + ln Pekerja Bebas + ln Upah Per Jam +
ln Berusaha Dibantu Buruh Tidak Tetap'
# Membuat dan melatih model
model2 = smf.ols(formula=formula, data=df t).fit()
# Menampilkan ringkasan model
print (model2.summary())
Model 3
#LN P1
formula = 'ln P1 ~ Tingkat Pengangguran + apm sd + apm smp + apm sma +
Berusaha Sendiri + Berusaha Dibantu Buruh Tetap + Buruh + Pekerja Bebas +
Upah Per Jam + Berusaha Dibantu Buruh Tidak Tetap'
# Membuat dan melatih model
model3 = smf.ols(formula=formula, data=df t).fit()
# Menampilkan ringkasan model
print (model3.summary())
Model 4
#SEMUA LN WEH
# Formula dengan nama kolom yang tepat menggunakan tanda kutip
formula = 'ln P1 ~ ln Tingkat Pengangguran + ln apm sd + ln apm smp +
ln apm sma + ln Berusaha Sendiri + ln Berusaha Dibantu Buruh Tetap +
ln Buruh + ln Pekerja Bebas + ln Upah Per Jam +
ln Berusaha Dibantu Buruh Tidak Tetap'
# Membuat dan melatih model
model4 = smf.ols(formula=formula, data=df t).fit()
```

```
# Menampilkan ringkasan model
print(model4.summary())
Skewness
y = df['P1']
X = df.drop(columns=['P1'])
from scipy.stats import skew
numeric cols = X.select dtypes(include=np.number).columns
skew x = X[numeric cols].apply(skew)
df['P1'] = pd.to numeric(df['P1'], errors='coerce')
skew_y = skew(df['P1'], nan_policy='omit')
print(f"Skewness X:\n{skew x}")
print(f"Skewness Y:\n {skew y}")
Best Model
model = {
    'Model': ['model1', 'model2', 'model3', 'model4'],
    'R-squared': [model1.rsquared, model2.rsquared, model3.rsquared,
                  model4.rsquared],
    'Adj. R-squared': [model1.rsquared adj, model2.rsquared adj,
model3.rsquared adj,
                      model4.rsquared adj],
    'AIC': [model1.aic, model2.aic, model3.aic,
            model4.aic],
    'BIC': [model1.bic, model2.bic, model3.bic,
            model4.bic],
    'F-statistic': [model1.fvalue, model2.fvalue, model3.fvalue,
                    model4.fvalue]
}
model comparison = pd.DataFrame(model)
print(model comparison)
```